PORTFOLIO

KIM JAEYOUNG

김재영

Linux 기반 시스템 구축 운영 경험
LLM 활용과 AI 서비스 구현

TECHNICAL PROFILE

SYSTEM OPERATIONS	Linux 서버 구축 · 운영 외부 시스템 연동
TROUBLESHOOTING	로그, PCAP 분석 현장 장애 대응
AI PROJECTS	로컬 LLM 추론 · AI 서비스 구현·운영

Phone	010.5092.2112
Email	totquf4171@gmail.com
GitHub	github.com/totjae/portfolio
ModelNaru	chat.mihoservice.xyz
Guest Code	testuser

경험 및 기술

통신 시스템 구축 · 운영과 로그 기반 문제 해결 경험을 AI 서비스 영역으로 확장하고 있습니다.

FIELD EXPERIENCE

사이버텔브릿지 · 시스템 엔지니어
2024.11–2026.04

- 함정 9척 구축 · 유지보수 참여
- 서버 · 단말 · 외부 연동 · 사용자 교육

SYSTEM / INFERENCE

- CentOS · Red Hat · 서버 구축·운영
- DB 이중화 · 로그·PCAP 분석
- llama.cpp · RPC 분산 추론
- 양자화 모델 비교 · 컨텍스트·레이어 배분 조정

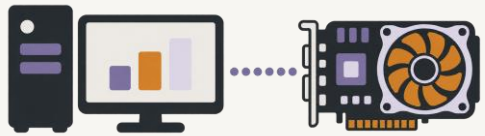
AI PROJECT STACK

- TypeScript · NestJS · PostgreSQL
- Docker Compose · Nginx
- LLM API · MCP · 대화 자동 요약
- 에이전트 연결 · 프롬프트 구성

로컬 LLM 추론 실험

llama.cpp · RPC · 양자화

- 이기종 GPU 간 RPC 분산 추론
- 양자화·컨텍스트·레이어 배분 조정



Linux 시스템 구축·운영

CentOS · Red Hat · MCPTT

- OS · 솔루션 설치 및 설정
- DB 동기화 · 이중화 · 유지보수



로그 기반 문제 해결

Server Log · PCAP · Device Log

- 서버·단말 로그와 PCAP을 분석해
- 시스템 동작 구조와 문제 원인을 파악



AI 서비스 구현·활용

ModelNaru · MCPex · 깨비랑

- 여러 모델 통합 · 대화 자동 요약
- 로컬 모델 작업 위임 · 에이전트 연결



해군 스마트쉽
무선 네트워크
MCPTT 통신 시스템

전용 서버와 무선 단말을 기반으로 음성 통신을 제공하고 함정 내 유선전화 · CCTV 등 외부 시스템과 연동하는 통신환경입니다.

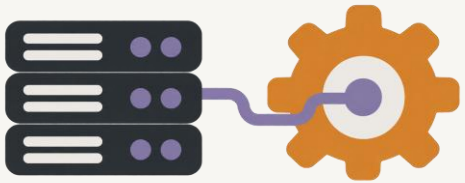
담당 업무

- Linux 서버 · 설루션 설치 및 설정
- 단말 점검 및 외부 시스템 연동
- 장애 대응과 사용자 교육



해군 스마트쉽 무선 네트워크
수행 업무

기간 2024.12 - 2026.04 | 소속 사이버텔브릿지 부산사무소(시스템사업부) | 대상 신조함 5척 운영함정 4척
직접 작업 함정 기준



Server
서버 구축·운영

- CentOS·Red Hat 및 솔루션 설치·설정
- Call·Record 서버 구성
- DB 이중화 · 데몬 장애 대응



Device
유지보수

- Android 무선 단말 점검·보수 (MCPTT단말, BLE 게이트웨이)
- OS 프리로드 · VPN·SSM 설정
- 단말 인식 상태·로그 확인



Integration
외부 연동

- IP-PBX 연동 설정
- 양방향 발신·수신·음성 전달 확인
- CCTV 연동 오류 분석·수정 요청



Test & Training
시험 및 교육

- 통합시험 사전 점검·시연
- 부하 발생 기능 적용·시험 지원
- 승조원 대상 사용 교육

해군 스마트쉽 무선 네트워크
문제해결 개선 사례

BLE 게이트웨이 이상 장비 탐색



문제	다수 장비에서 단말 BLE 신호 인식 실패
조치	로그 판정 기준 수립 · Python 분석 도구 제작 및 활용
결과	이상 장비 특정 · 점검 범위 축소 및 보수 완료

FOTA 업데이트 통신 복구



문제	FOTA 소프트웨어의 목적지 주소 오류로 업데이트 실패
조치	PCAP 분석 · 방화벽 업체에 NAT 적용 요청
결과	업데이트 정상화 · 전체 장비 분해·수동 작업 회피 수동 작업 시 2주 이상 소요 예상

CCTV 순차 등록 중단 해결



문제	한 장비 등록 실패 시 이후 장비 등록 중단
조치	동작 흐름 분석·재현 시험 · 개발팀 수정 요청
결과	개발팀 수정으로 후속 장비 등록 중단 문제 해결

※ 보안·운영 특성상 세부 로그와 망 구성은 면접 시 공개 가능한 범위 안에서 설명

추가 현장 경험

부산 지하철 2~4호선 LTE-R 단말 납품

2025.01 - 2026.01

- 납품 단말 초기 세팅
- 대상 역사별 방문 · 단말 배포
- 역무원 대상 사용법 · 기능 안내



MADEX 해양방위산업전

2025.05.28 - 2025.05.31

- 전시 장비 · 시연 환경 초기 세팅 지원
- 스마트쉽 · MCPTT 솔루션 기능 설명
- 방문객 · 관계자 대상 직접 시연



ModelNaru

여러 AI모델을 하나의 대화 환경으로

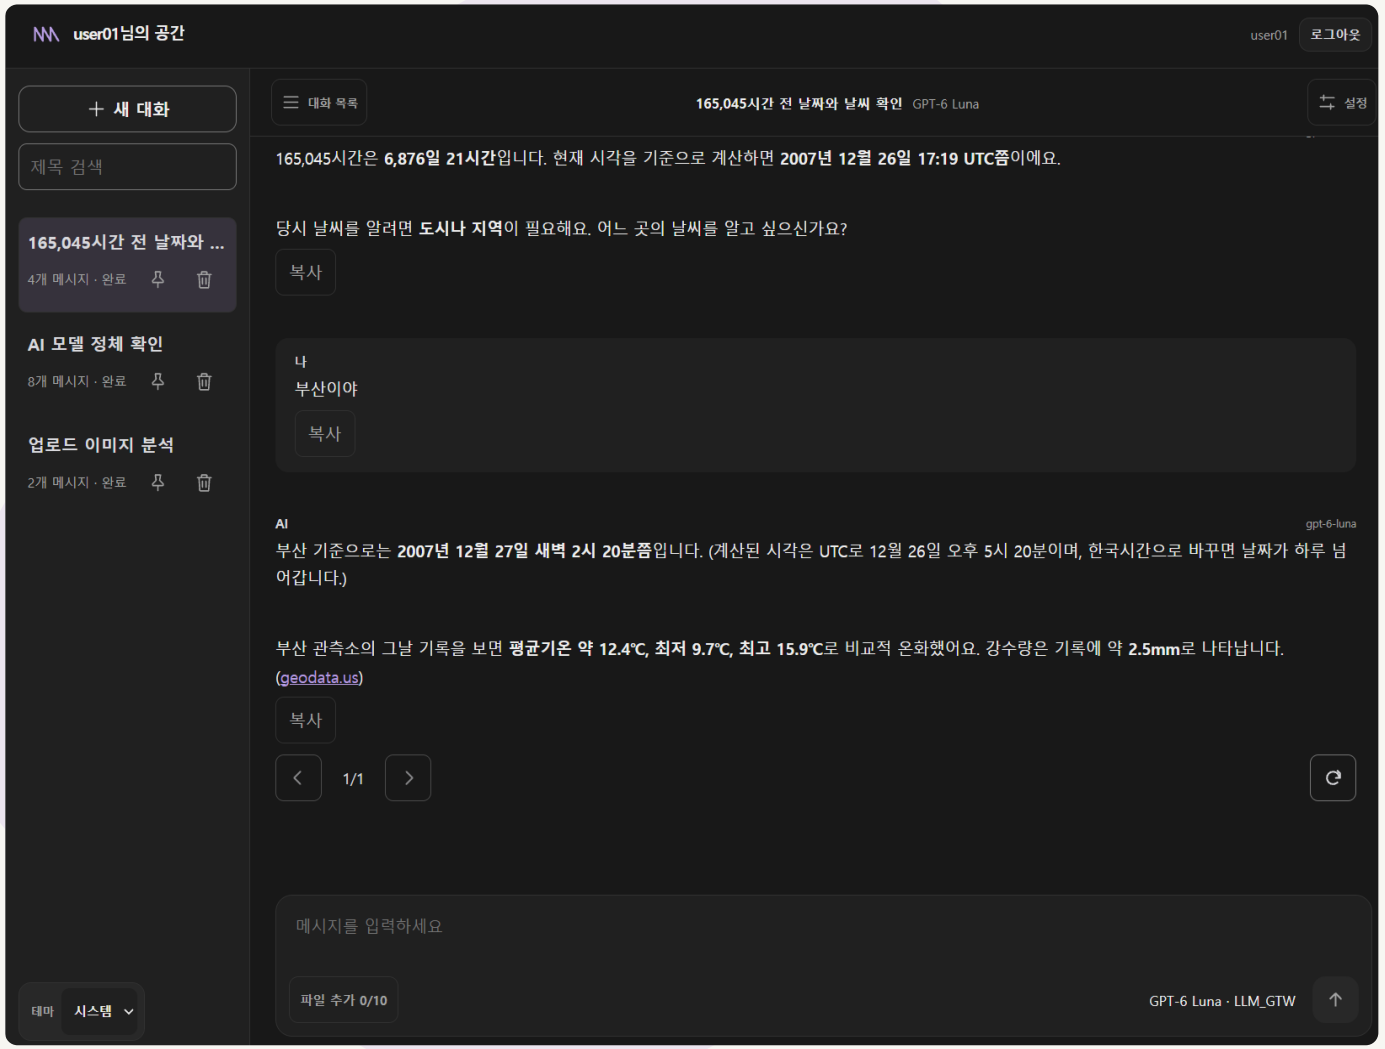
목적에 맞는 모델을 선택하고, 모델별 기능과 시스템 프롬프트를 설정해 사용자가 원하는 방식으로 사용하는 AI 채팅 플랫폼입니다.

- **다양한 모델 선택** | 여러 Provider의 모델을 하나의 화면에서
- **나만의 대화 설정** | 시스템 프롬프트·생성 파라미터 조정
- **확장된 입력** | 웹검색·이미지 입력 · PDF OCR
- **대화 자동 관리** | 대화 제목 자동 생성 · 이전 대화 자동 요약

모델별 지원 기능 상이

chat.mihoservice.xyz

실사용 화면



Provider가 늘어나도 실행 흐름은 하나로

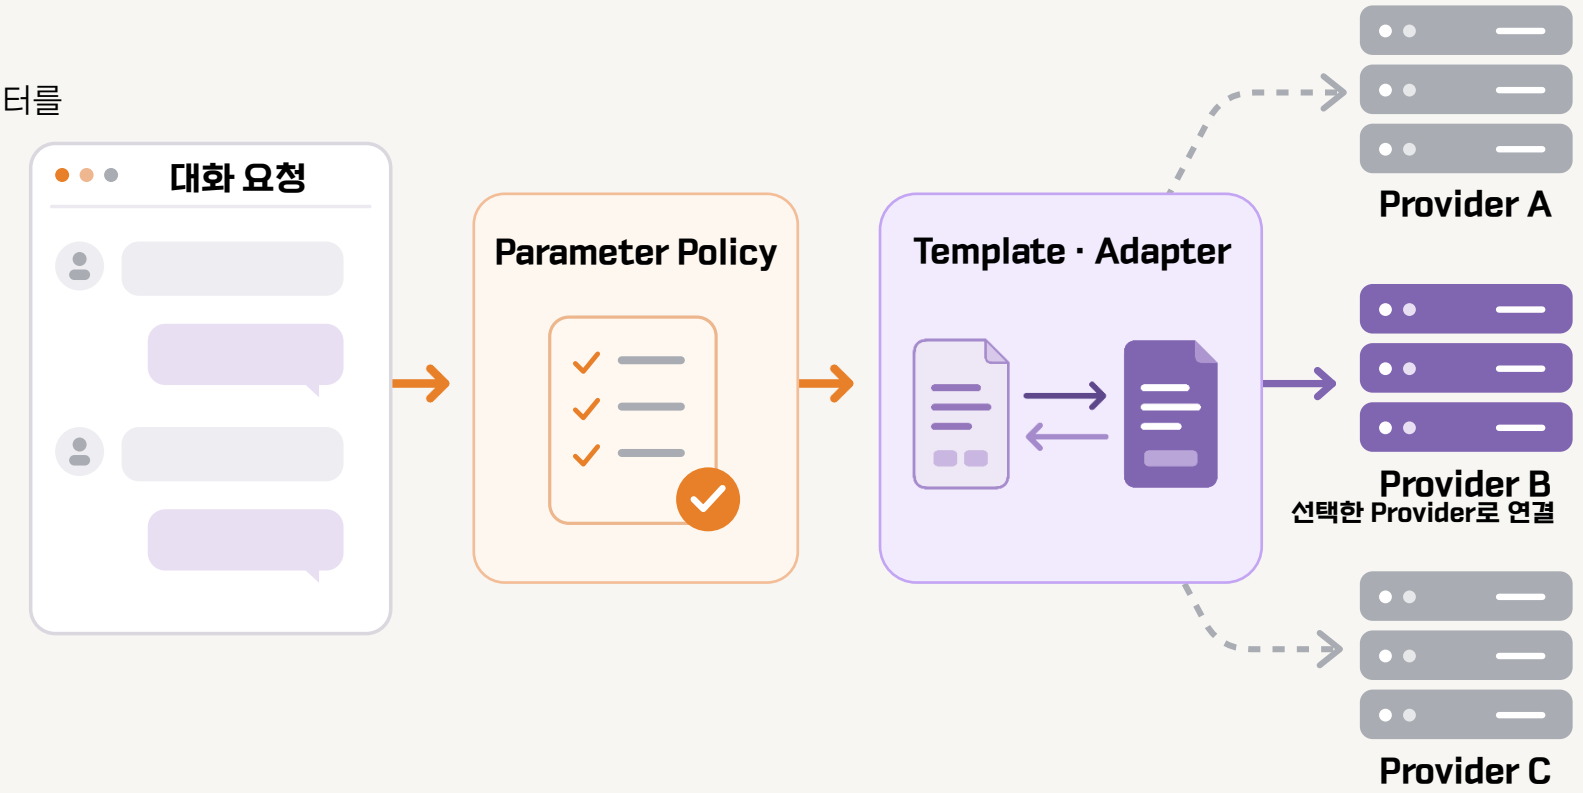
Provider마다 다른 인증 방식과 요청·응답 형식을 Template과 Adapter로 분리했습니다. 모델별 지원 파라미터를 확인해 동일한 환경에서 여러 Provider를 사용할 수 있도록 구성했습니다.

Parameter Policy

모델별 지원 파라미터 확인
미지원 값 제외

Template · Adapter

Provider별 인증 · 연결 및 요청 · 응답 형식 차이 처리



ModelNaru

대화 설정과 맥락 관리

대화마다 원하는 설정으로 길어진 대화도 이어서

대화별로 모델과 시스템프롬프트, 생성 파라미터를 설정합니다. 오래된 메시지는 요약하고 최근 원문과 함께 전달해 이전 맥락을 이어갑니다.

모델 응답 설정

모델 · 시스템 프롬프트 · 생성 파라미터

입력·기능 설정

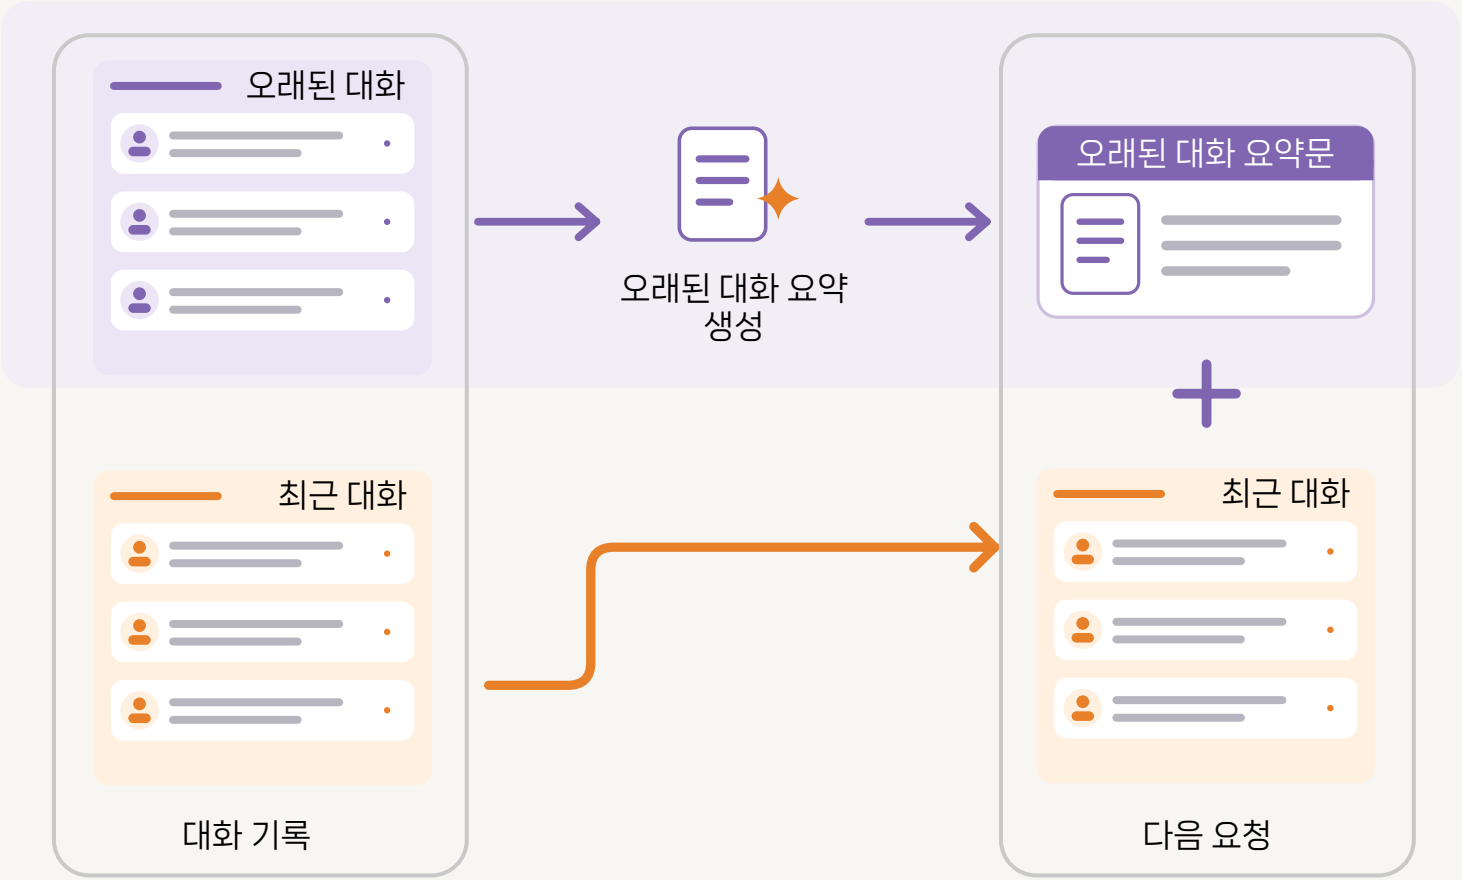
모델별 웹검색 · 이미지 입력

대화 제목 자동 생성

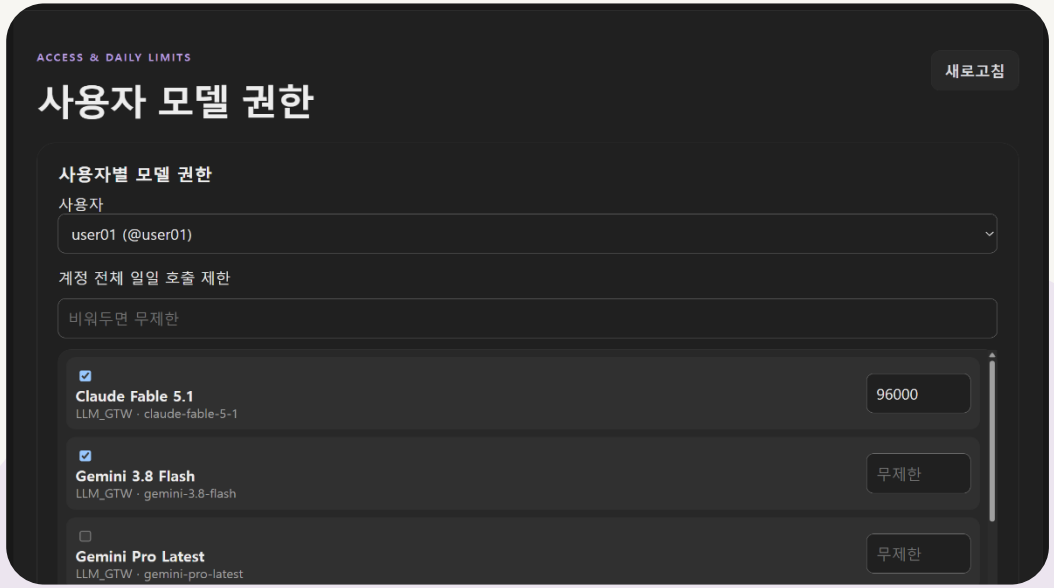
대화 내용을 바탕으로 제목 생성

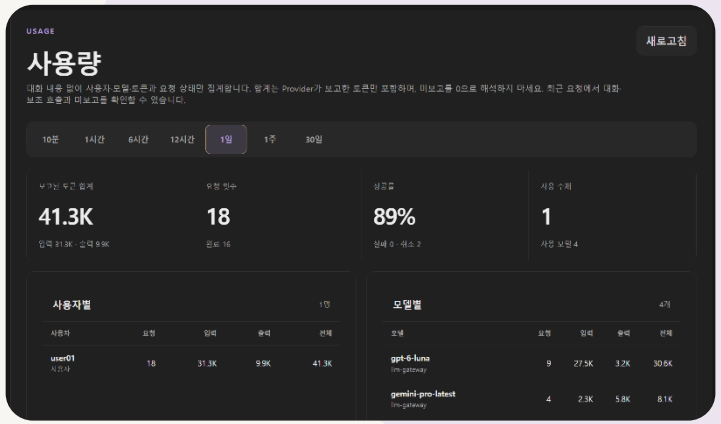
컨텍스트 관리

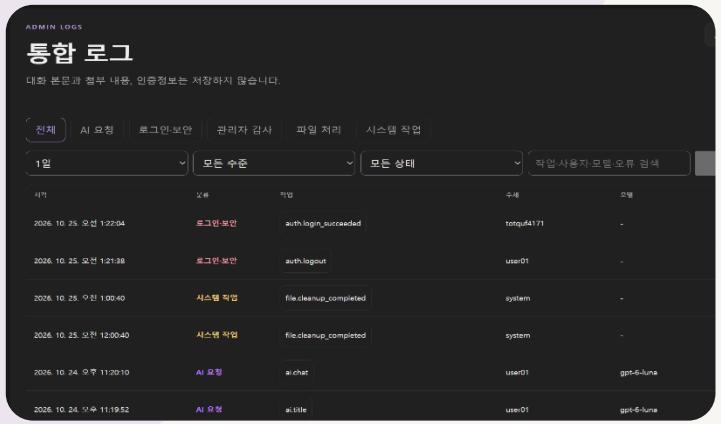
이전 메시지 수 · 컨텍스트 한도 · 자동 요약



실사용 중인 관리자 페이지







ModelNaru

사용자별 접근을 관리하고, 모델 사용 현황을 한눈에

사용자 · 게스트별 모델 접근 권한과 호출 제한을 설정합니다. Provider · 모델별 사용량과 요청 상태, 토큰 사용량 · 처리 시간을 확인할 수 있습니다.

접근 제어 사용자 · 게스트별 모델 권한 · 호출 제한

사용량 조회 Provider · 모델별 호출 및 토큰 사용량

요청 기록 성공·실패·취소 상태 · 요청 처리 시간

ModelNaru

문제 해결

01

Provider별 생성 파라미터 호환성

문제 Provider별 지원 파라미터 차이로 동일 설정 전달 시 오류 발생

개선 Provider/Model별 Parameter Policy 구성
미지원 값 제거 및 UI 비활성화 사유 표시

결과 Provider 차이를 공통 검증 구조에서 처리

02

SSE Streaming 메모리·연결 안정성

문제 느린 Client 환경에서 Provider Stream 적체 시 Node 메모리 증가 가능

개선 Backpressure 처리, drain 대기,
Provider Idle Timeout 브라우저 연결 종료 시 upstream 중단

결과 느린 Client와 비정상 연결의 자원 점유 제한

03

PDF/OCR 동시 처리의 자원 고갈

문제 Poppler/Tesseract 동시 실행 증가 시 CPU·Memory 고갈 위험

개선 Bounded Worker Queue 적용
PDF Worker 1 / Queue 4,
OCR Worker 1 / Queue 4

결과 파일 처리량을 서버 수용 범위 내로 제한

로컬 LLM 분산 추론

llama.cpp RPC 기반 이종 GPU 연결

한 장의 GPU에 담기 어려운 모델을 두 장비에 나누어 실행

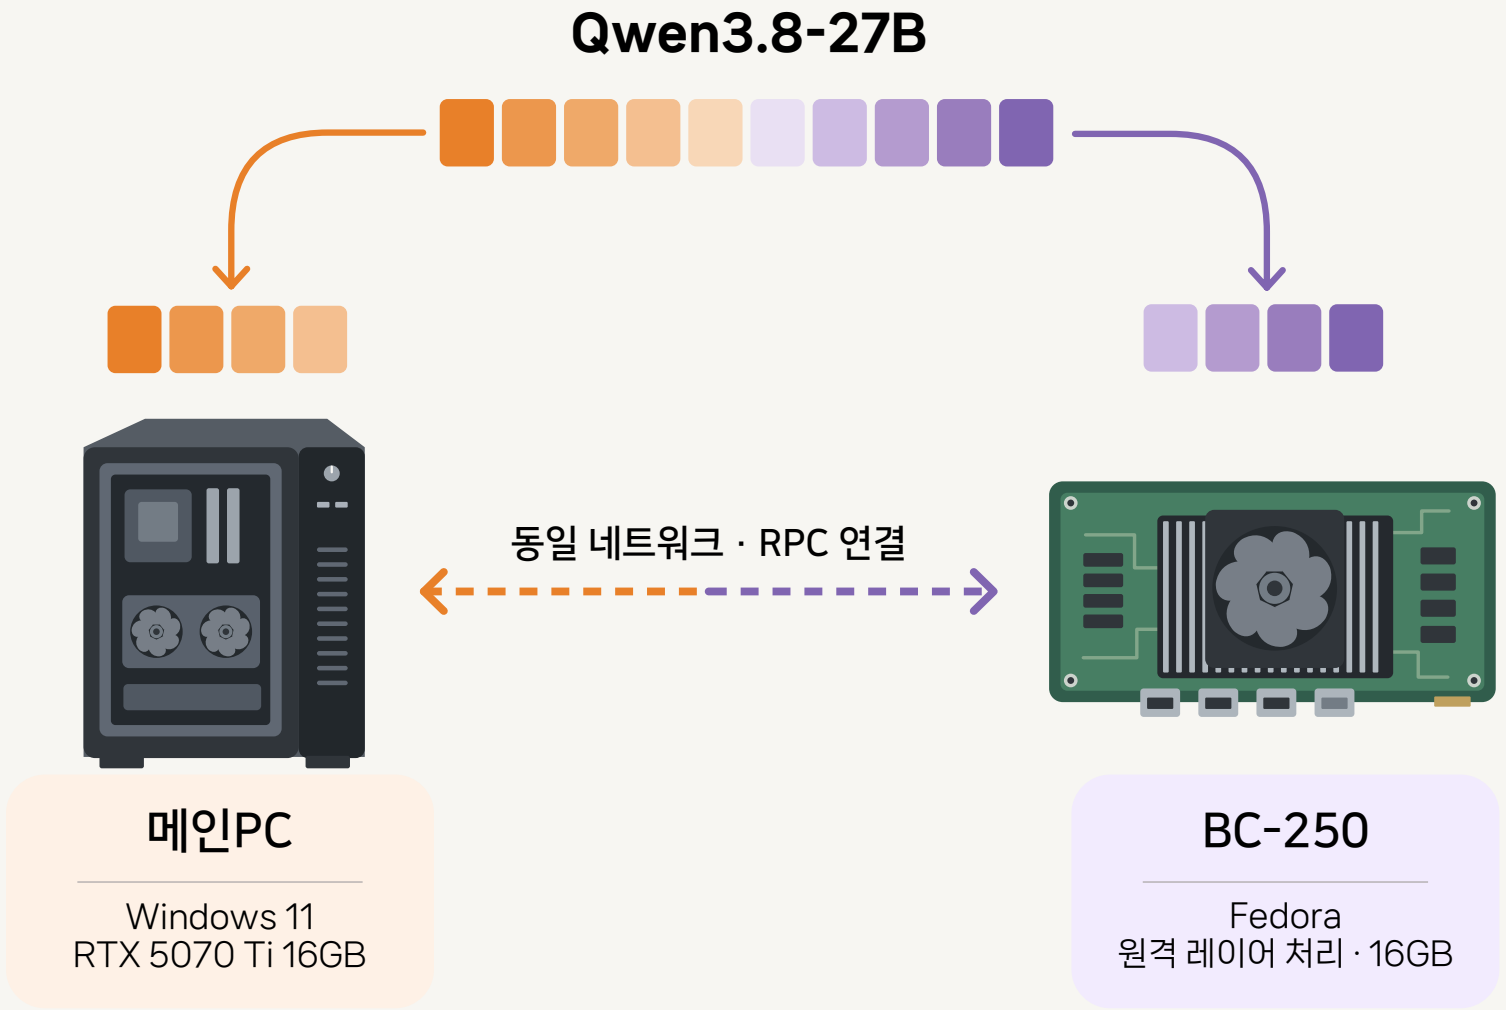
16GB GPU의 메모리 부족을 보완하기 위해 BC-250을 추가 활용했습니다. 같은 네트워크의 두 장비에 모델 레이어를 분배해 Qwen3.8-27B 모델의 답변 생성을 확인했습니다.

수행 내용

모델 선정 · 양자화 설정별 테스트
이기종 GPU 연결 · 분산 실행 환경 구성
레이어 배분 비율 · 추론 설정 최적화
메모리 사용량 · 실제 추론 성능 검증

실험 결과

단일 GPU 메모리 제약을 보완해 답변 생성 성공
분산 실행의 생성 속도와 실사용 적합성 확인
성능상 한계로 장비별 적합 모델 독립 실행으로 전환



MCPex

작은 로컬 모델이라도 활용할 수 있도록 도와주는 MCP 서비스

코딩 에이전트에서 활용할 수 있도록 MCP로 AI API를 연결하는 도구입니다.
메인 에이전트의 사용량 절감을 목표로 MCP를 연결하고 실제 코드 작업에 활용했습니다.



주요 이슈와 대응

메인 에이전트에서 MCP 도구 미호출
서버 · 도구 이름과 위임 조건을 지침에 명시

호출 도구의 부정확한 코드 분석
오류 피드백을 통한 재작업 · 재검증 방식 요구

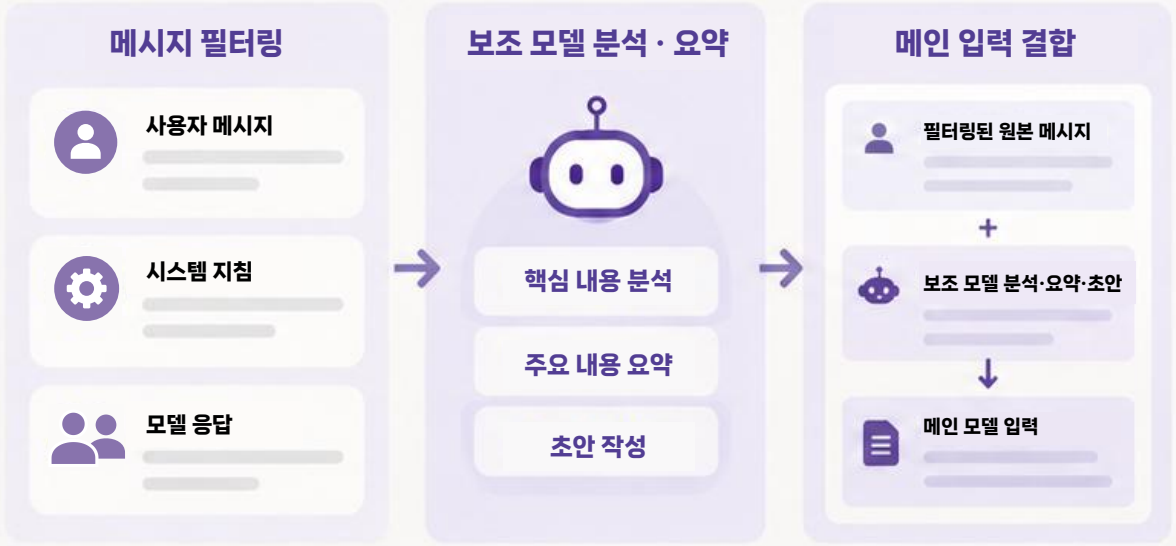
위임 결과 재검토 비용 증가
위임 작업 체계화, 자가 검토, 검토 방식 변경

기타 프로젝트

Context Loom

멀티 에이전트 컨텍스트 파이프라인

메시지를 역할별로 필터링하고, 보조 모델이 생성한 분석 · 요약 · 초안을 메인 모델 입력에 결합하는 프로젝트입니다.



출력 품질 개선 · 컨텍스트 공간 확보를 위한 입력 구성 자동화

깨비랑

장소와 이야기를 연결하는 AI RP 관광 가이드

도깨비가 관광지를 추천하고, 선택한 장소와 관련된 인물 도슨트가 도슨트의 관점에서 해설을 이어가는 챗봇입니다.



2인 팀
김재영 : 공동 기획 · 플랫폼 에이전트 연결 · 프롬프트 구성
정재훈 : 관광 기획, QA

도깨비 지역 추천과 도슨트 전환 후 관광지 해설 작동 시연